

Artikel

Evaluasi Performa Prediksi Probabilistik pada Klasifikasi Kualitas Air Menggunakan Algoritma Natural Gradient Boosting (NGBoost)

Aflah Zaki Siregar¹, Siti Zahrotul Fajriyah, S.Kom., M.Kom.²¹ Teknologi Informasi, Telkom University, Bandung, Indonesia² Informatika, Telkom University, Bandung, Indonesia

* Correspondence: aflahzaki@student.telkomuniversity.ac.id

† Alamat saat ini: Jakarta, Setiabudi.

‡ Semua penulis telah berkontribusi.

Abstract: Pendekatan *machine learning* deterministik yang dominan pada domain kualitas air hanya menghasilkan prediksi titik tunggal tanpa mengkuantifikasi ketidakpastian inheren pada data parameter fisikokimia. Penelitian ini mengevaluasi kerangka kerja prediksi probabilistik berbasis *Natural Gradient Boosting* (NGBoost) untuk klasifikasi kelayakan air minum menggunakan *Water Potability Dataset* (3.276 sampel, 9 parameter fisikokimia). NGBoost memodelkan distribusi penuh probabilitas melalui parameterisasi distribusi Bernoulli dan optimasi berbasis *Natural Gradient* pada *Fisher Information Matrix*. Pra-pemrosesan mencakup imputasi MICE, standarisasi fitur, dan pembagian data *stratified* 70:15:15. Hasil evaluasi pada set uji (N=492) menunjukkan bahwa NGBoost, XGBoost, dan *Random Forest* memiliki performa klasifikasi yang setara secara statistik (akurasi 0,665; 0,665; 0,659; uji McNemar $p > 0,75$ untuk semua pasangan). Pada metrik kalibrasi, NGBoost memperoleh NLL=0,673 dan ECE=0,069, sedangkan *Random Forest* mencapai NLL=0,618 dan ECE=0,042. Meskipun NGBoost tidak mengungguli *baseline* pada metrik kalibrasi, keunggulan utamanya terletak pada kerangka probabilistik natif yang memungkinkan kuantifikasi ketidakpastian secara prinsipil. Analisis zona ketidakpastian menunjukkan korespondensi bermakna antara probabilitas prediksi dan reliabilitas aktual model.

Kata Kunci: Natural Gradient Boosting; prediksi probabilistik; kualitas air; kalibrasi probabilistik; kuantifikasi ketidakpastian; MICE



Citation: Siregar, A.Z.; Fajriyah, S.Z.
NGBoost untuk Prediksi Probabilistik
Kualitas Air. *Met. Lit. Ta. Tul* 2024, 1,
0. <https://doi.org/>

Received:

Revised:

Accepted:

Published:



Copyright: © 2024 by the authors.
Licensee CITI Labs, Dayeuhkolot,
Bandung, Jawa Barat, Indonesia.
Artikel ini terbuka sesuai syarat
dan ketentuan yang berlaku
menggunakan Creative Commons
Attribution (CC BY) license (<https://creativecommons.org/licenses/by/4.0/>).

1. Pendahuluan

Kualitas air minum yang memenuhi standar kelayakan merupakan prasyarat fundamental bagi kesehatan masyarakat. Penentuan status kelayakan konsumsi bergantung pada analisis parameter fisikokimia seperti pH, kekeruhan, total padatan terlarut, kloramin, sulfat, konduktivitas, karbon organik, dan trihalometana [1–3]. Parameter-parameter tersebut memiliki variabilitas alami yang tinggi akibat faktor lingkungan dan keterbatasan presisi pengukuran, sehingga menciptakan ketidakpastian signifikan pada data observasi [4].

Pemanfaatan *machine learning* untuk analisis kualitas air berkembang pesat dalam dekade terakhir. Algoritma *ensemble* seperti *Random Forest* dan XGBoost telah banyak diterapkan untuk klasifikasi kelayakan air minum dengan akurasi yang kompetitif [1,2,4]. Namun, pendekatan konvensional tersebut bersifat deterministik dan hanya menghasilkan *point estimate* tanpa memodelkan distribusi penuh dari ketidakpastian prediksi [5]. Dalam konteks pengambilan keputusan berisiko seperti penentuan kelayakan air minum, ketidakmampuan model mengkuantifikasi tingkat kepercayaan terhadap prediksi menjadi kelemahan mendasar.

Natural Gradient Boosting (NGBoost) hadir sebagai algoritma *boosting* generik yang memodelkan distribusi penuh probabilitas dengan memanfaatkan *Natural Gradient* pada ruang parameter distribusi berbasis *Fisher Information Matrix* [5]. NGBoost telah terbukti efektif pada berbagai domain: estimasi *State of Charge* baterai [6], prediksi risiko finansial [7], dan prediksi mutasi somatik [8]. Namun, penerapannya pada klasifikasi kelayakan air minum yang secara spesifik mengevaluasi kalibrasi probabilistik masih merupakan area yang belum tereksplorasi.

Berdasarkan kesenjangan tersebut, penelitian ini merumuskan tiga pertanyaan: (1) Bagaimana performa NGBoost dalam memodelkan distribusi probabilitas kelayakan air minum dibandingkan model *ensemble* deterministik? (2) Bagaimana tingkat kalibrasi probabilitas NGBoost dibandingkan XGBoost dan *Random Forest*? (3) Bagaimana karakteristik ketidakpastian prediksi pada instance di sekitar ambang batas keputusan? Hipotesis penelitian ini adalah bahwa kerangka probabilistik natif NGBoost memungkinkan kuantifikasi ketidakpastian yang lebih prinsipil meskipun metrik kalibrasi numerik belum tentu lebih unggul. Struktur artikel ini terdiri atas: Bagian 2 membahas penelitian terkait, Bagian 3 menyajikan metodologi, Bagian 4 memaparkan hasil percobaan, dan Bagian 5 menyimpulkan temuan.

2. Penelitian Terkait

Penelitian di domain kualitas air didominasi oleh pendekatan deterministik. Aslam et al. [1] menerapkan *hybrid neural network* dan XGBoost untuk manajemen kualitas sungai Indus, Park et al. [2] mengembangkan model *ensemble* untuk penilaian kualitas air, dan Al Bataineh et al. [4] mengimplementasikan XGBoost dengan *feature-based neural network* pada dataset *Water Potability*. Ketiga studi tersebut menghasilkan akurasi kompetitif namun hanya berupa *point estimate* tanpa estimasi ketidakpastian. Penelitian lain oleh Ahmed et al. [3], Uddin et al. [9], Khoi et al. [10], dan Sakaa et al. [11] mengonfirmasi dominasi pendekatan deterministik pada domain ini.

Di sisi lain, pendekatan probabilistik telah menunjukkan keunggulan di domain lain. Duan et al. [5] memperkenalkan NGBoost sebagai algoritma *boosting* yang memodelkan distribusi penuh probabilitas. Li et al. [6] menerapkan NGBoost untuk estimasi probabilitas SoC baterai, Zhu et al. [7] mengintegrasikan SMOTE-ENN dengan NGBoost untuk risiko finansial, dan Marzo et al. [8] mengadaptasi NGBoost untuk prediksi mutasi somatik. Studi-studi tersebut memberikan indikasi bahwa NGBoost dapat diadaptasi untuk domain kualitas air.

Tabel 1. Perbandingan Penelitian Terdahulu

Peneliti & Tahun	Metode	Domain	Tipe Prediksi	Keterbatasan
Aslam et al. (2022)	NN + XGBoost	Sungai Indus	Deterministik	Tanpa estimasi ketidakpastian
Park et al. (2022)	ML Ensemble	Kualitas air	Deterministik	Point estimate tanpa kalibrasi
Al Bataineh et al. (2026)	XGBoost + NN	Water Potability	Deterministik	Probabilitas titik
Li et al. (2024)	NGBoost	SoC Baterai	Probabilistik	Domain non-air
Zhu et al. (2023)	SMOTE-ENN + NGBoost	Risiko Finansial	Probabilistik	Domain non-air
Penelitian Ini	NGBoost	Water Potability	Probabilistik	Mengisi gap domain air

Tabel 1 menunjukkan bahwa penerapan prediksi probabilistik pada domain kualitas air masih menjadi celah penelitian yang belum terisi. Penelitian ini berkontribusi dengan menerapkan NGBoost pada klasifikasi kelayakan air minum dan mengevaluasi kalibrasi probabilistiknya secara komprehensif.

3. Metodologi

3.1. Dataset

Penelitian ini menggunakan *Water Potability Dataset* [12] yang terdiri atas 3.276 sampel dengan 9 fitur parameter fisikokimia dan target biner kelayakan. Distribusi kelas menunjukkan ketidakseimbangan moderat: 1.998 sampel (60,99%) berlabel *Not Potable* dan 1.278 sampel (39,01%) berlabel *Potable*. Dataset mengandung nilai hilang pada tiga fitur: pH

sebanyak 491 (14,99%), Sulfate sebanyak 781 (23,84%), dan Trihalomethanes sebanyak 162 (4,95%).

3.2. Pra-pemrosesan Data

Pipeline pra-pemrosesan terdiri atas tahapan berikut. Pertama, imputasi nilai hilang menggunakan MICE (*Multivariate Imputation by Chained Equations*) yang mempertahankan struktur korelasi multivariat antar parameter fisikokimia [13,14]. Kedua, pembagian data secara *stratified* dengan rasio 70:15:15, menghasilkan set latih (N=2.292), set validasi (N=492), dan set uji (N=492). Ketiga, standarisasi fitur menggunakan *StandardScaler* yang di-fit hanya pada set latih untuk mencegah *data leakage*.

SMOTE-ENN dievaluasi secara kondisional sebagai teknik penanganan ketidakseimbangan kelas [15,16]. Namun, hasil evaluasi menunjukkan bahwa penerapan SMOTE-ENN mereduksi jumlah sampel latih dari 2.292 menjadi sekitar 1.096 dan menurunkan performa seluruh model secara signifikan. Oleh karena itu, SMOTE-ENN tidak diterapkan pada pipeline final.

3.3. Model NGBoost

NGBoost memodelkan distribusi kondisional $P(y | \mathbf{x})$ dengan mengoptimasi parameter distribusi secara iteratif menggunakan *Natural Gradient* [5]. Untuk klasifikasi biner, digunakan distribusi Bernoulli:

$$P(y | \mu) = \mu^y (1 - \mu)^{1-y} \quad (1)$$

di mana $\mu \in (0, 1)$ adalah parameter probabilitas yang diestimasi oleh model. Fungsi *scoring rule* yang digunakan adalah *Negative Log-Likelihood* (NLL):

$$\mathcal{L}(\mu, y) = -[y \log \mu + (1 - y) \log(1 - \mu)] \quad (2)$$

Optimasi parameter dilakukan menggunakan *Natural Gradient* yang memperhitungkan geometri ruang distribusi melalui *Fisher Information Matrix* (FIM):

$$\tilde{\nabla}_{\theta} = \mathcal{I}(\theta)^{-1} \nabla_{\theta} \mathcal{L} \quad (3)$$

di mana $\mathcal{I}(\theta) = \mathbb{E}[\nabla_{\theta} \log P(y|\theta) \cdot \nabla_{\theta} \log P(y|\theta)^T]$ adalah FIM. Pendekatan ini menghasilkan pembaruan yang bersifat *reparameterization-invariant*, berbeda dari *gradient descent* standar yang beroperasi pada ruang Euclidian [17].

3.4. Model Baseline

Dua model baseline deterministik digunakan untuk perbandingan: (1) XGBoost [18], algoritma *gradient boosting* yang mengoptimasi fungsi objektif dengan regularisasi pada struktur pohon; dan (2) *Random Forest* [19], *ensemble* pohon keputusan dengan *bagging* dan seleksi fitur acak. Probabilitas prediksi dari kedua model baseline diperoleh melalui mekanisme internal masing-masing algoritma.

3.5. Metrik Evaluasi


Evaluasi dilakukan pada dua aspek. Pertama, metrik klasifikasi meliputi *Accuracy*, *Precision*, *Recall*, *F1-Score*, dan AUC-ROC [20]. Kedua, metrik kalibrasi probabilistik meliputi NLL (Persamaan 2) dan *Expected Calibration Error* (ECE) [21]:

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{N} |\text{acc}(B_m) - \text{conf}(B_m)| \quad (4)$$

di mana B_m adalah bin ke- m , $\text{acc}(B_m)$ adalah akurasi aktual, dan $\text{conf}(B_m)$ adalah rata-rata probabilitas prediksi dalam bin tersebut ($M = 10$). Perbandingan antar model dilakukan menggunakan uji McNemar [22] untuk menguji signifikansi statistik perbedaan performa.

3.6. Diagram Alir

Gambar 1 mengilustrasikan keseluruhan alur metodologi penelitian dari tahap pengumpulan data hingga evaluasi.



Gambar 1. Diagram alir metodologi penelitian.

4. Hasil Percobaan

4.1. Hasil Klasifikasi dan Kalibrasi

Tabel 2 menyajikan perbandingan performa ketiga model pada set uji (N=492). Ketiga model menunjukkan performa klasifikasi yang serupa, dengan akurasi NGBoost dan XGBoost identik (0,665) dan *Random Forest* sedikit lebih rendah (0,659).

Tabel 2. Perbandingan Performa Model pada Set Uji (N=492)

Model	Acc	Prec	Rec	F1	NLL	ECE	AUC
NGBoost	0,665	0,667	0,281	0,396	0,673	0,069	0,651
XGBoost	0,665	0,634	0,333	0,437	0,624	0,058	0,650
Random Forest	0,659	0,630	0,302	0,409	0,618	0,042	0,667


Hasil menunjukkan bahwa NGBoost tidak mengungguli model *baseline* pada metrik kalibrasi (NLL dan ECE). *Random Forest* justru memperoleh ECE terendah (0,042) dan NLL

terendah (0,618), diikuti XGBoost (ECE=0,058, NLL=0,624), sedangkan NGBoost memperoleh ECE=0,069 dan NLL=0,673. Pada metrik klasifikasi, NGBoost memiliki *precision* tertinggi (0,667) namun *recall* terendah (0,281), yang mengindikasikan kecenderungan model untuk lebih konservatif dalam memprediksi kelas *Potable*.

Uji McNemar menunjukkan bahwa tidak terdapat perbedaan signifikan secara statistik antara pasangan model mana pun, dengan seluruh nilai $p > 0,75$. Hasil ini mengonfirmasi bahwa performa klasifikasi ketiga model setara secara statistik pada dataset ini.

4.2. Confusion Matrix

Gambar 2 menampilkan *confusion matrix* ketiga model. NGBoost menghasilkan TN=273, FP=27, FN=138, TP=54; XGBoost menghasilkan TN=263, FP=37, FN=128, TP=64; dan *Random Forest* menghasilkan TN=266, FP=34, FN=134, TP=58.



Gambar 2. Perbandingan *confusion matrix* ketiga model pada set uji.

Pola yang konsisten terlihat pada ketiga model: jumlah *False Negative* jauh lebih tinggi dibandingkan *False Positive*, mengindikasikan kesulitan seluruh model dalam mendeteksi sampel kelas *Potable* (minoritas). NGBoost memiliki FP terendah (27) yang sejalan dengan *precision* tertingginya, sementara XGBoost memiliki TP tertinggi (64) yang sejalan dengan *recall* tertingginya.

4.3. Dampak SMOTE-ENN

SMOTE-ENN dievaluasi sebagai strategi penanganan ketidakseimbangan kelas. Tabel 3 menunjukkan perbandingan akurasi dengan dan tanpa penerapan SMOTE-ENN.

Tabel 3. Dampak SMOTE-ENN terhadap Akurasi Model

Kondisi	NGBoost	XGBoost	Random Forest
Tanpa SMOTE-ENN	0,665	0,665	0,659
Dengan SMOTE-ENN	0,549	0,577	0,585

Penerapan SMOTE-ENN menurunkan performa seluruh model secara substansial. Penurunan terbesar terjadi pada NGBoost (dari 0,665 menjadi 0,549), diikuti XGBoost (dari 0,665 menjadi 0,577) dan *Random Forest* (dari 0,659 menjadi 0,585). Penyebabnya adalah SMOTE-ENN mereduksi jumlah sampel latih dari 2.292 menjadi sekitar 1.096, yang mengurangi informasi yang tersedia untuk pelatihan. Berdasarkan temuan ini, SMOTE-ENN tidak diterapkan pada pipeline final.

4.4. Analisis Zona Ketidakpastian

Keunggulan utama NGBoost terletak pada kerangka probabilistik natifnya yang memungkinkan analisis zona ketidakpastian. Tabel 4 menyajikan pembagian prediksi NGBoost berdasarkan lima zona probabilitas.


Tabel 4. Analisis Zona Ketidakpastian NGBoost

Zona	Jumlah (%)	Akurasi
Zona 1 ($\mu < 0,2$)	97 (19,7%)	72,2%
Zona 2 ($0,2 \leq \mu < 0,4$)	222 (45,1%)	67,1%
Zona 3 ($0,4 \leq \mu < 0,6$)	130 (26,4%)	56,2%
Zona 4 ($0,6 \leq \mu < 0,8$)	25 (5,1%)	76,0%
Zona 5 ($\mu \geq 0,8$)	18 (3,7%)	88,9%


Hasil menunjukkan korespondensi bermakna antara probabilitas prediksi dan reliabilitas aktual. Instance pada zona dengan kepercayaan tinggi (Zona 5, $\mu \geq 0,8$) memiliki akurasi 88,9%, sementara instance pada zona ambigu (Zona 3, $0,4 \leq \mu < 0,6$) memiliki akurasi terendah 56,2%. Pola ini menunjukkan bahwa output probabilistik NGBoost memberikan sinyal informatif mengenai reliabilitas prediksi. Zona 2 mendominasi dengan 45,1% instance, mengindikasikan bahwa sebagian besar sampel berada pada area yang memerlukan kehati-hatian dalam interpretasi.

4.5. Distribusi Probabilitas dan Kurva Loss

Gambar 3 menampilkan distribusi probabilitas prediksi NGBoost, yang mengilustrasikan bagaimana model mendistribusikan kepercayaannya terhadap kedua kelas.


**Gambar 3.** Distribusi probabilitas prediksi NGBoost pada set uji.

Gambar 4 menyajikan kurva *loss* selama pelatihan NGBoost, menunjukkan konvergensi model dan tidak adanya indikasi *overfitting* yang signifikan.

**Gambar 4.** Kurva *loss* NGBoost selama pelatihan.

4.6. Feature Importance

Gambar 5 menampilkan tingkat kepentingan fitur pada model NGBoost, yang membantu mengidentifikasi parameter fisikokimia yang paling berpengaruh terhadap prediksi kelayakan air.



Gambar 5. Feature importance pada model NGBoost.

4.7. Diskusi

Temuan utama penelitian ini dapat dirangkum sebagai berikut. Pertama, ketiga model memiliki performa klasifikasi yang setara secara statistik (uji McNemar $p > 0,75$), mengindikasikan bahwa pada dataset ini tidak ada satu model pun yang secara signifikan lebih unggul. Kedua, berlawanan dengan ekspektasi awal, NGBoost tidak menghasilkan kalibrasi yang lebih baik dibandingkan *baseline*. *Random Forest* justru mencapai ECE dan NLL terendah. Hal ini dapat disebabkan oleh karakteristik dataset yang relatif sederhana (9 fitur, distribusi kelas moderat), di mana probabilitas internal *Random Forest* yang dihitung dari proporsi voting pohon sudah cukup terkalibrasi tanpa memerlukan optimasi distribusi eksplisit.

Ketiga, keunggulan NGBoost terletak bukan pada metrik numerik yang lebih baik, melainkan pada kerangka probabilistik natifnya. NGBoost secara eksplisit mengoptimasi parameter distribusi melalui *Natural Gradient*, yang memberikan fondasi teoretis yang lebih kuat untuk kuantifikasi ketidakpastian. Analisis zona ketidakpastian (Tabel 4) membuktikan bahwa output probabilistik NGBoost memiliki korespondensi bermakna dengan reliabilitas aktual, yang berguna untuk pengambilan keputusan bertingkat dalam aplikasi nyata.

Keempat, SMOTE-ENN terbukti kontraproduktif pada dataset ini. Reduksi drastis jumlah sampel latih akibat tahap *Edited Nearest Neighbors* menghilangkan informasi yang diperlukan model untuk belajar pola diskriminatif, sehingga akurasi seluruh model menurun secara substansial.

5. Simpulan

Penelitian ini mengevaluasi performa prediksi probabilistik NGBoost pada klasifikasi kelayakan air minum dan membandingkannya dengan XGBoost dan *Random Forest*. Hasil pada set uji (N=492) menunjukkan bahwa ketiga model memiliki performa yang setara secara statistik (uji McNemar $p > 0,75$). NGBoost tidak mengungguli *baseline* pada metrik kalibrasi (ECE=0,069 vs. *Random Forest* ECE=0,042), namun kerangka probabilistik natifnya memungkinkan kuantifikasi ketidakpastian yang lebih prinsipil melalui parameterisasi distribusi eksplisit. Analisis zona ketidakpastian menunjukkan korespondensi bermakna antara probabilitas prediksi dan reliabilitas aktual, di mana instance dengan kepercayaan tinggi ($\mu \geq 0,8$) mencapai akurasi 88,9%.

Keterbatasan penelitian ini meliputi: (1) penggunaan dataset statis yang tidak merepresentasikan variasi temporal, (2) terbatas pada 9 parameter fisikokimia tanpa parameter biologis, dan (3) skema klasifikasi biner yang tidak mencakup gradasi kualitas. Penelitian selanjutnya dapat mengeksplorasi penerapan NGBoost pada dataset yang lebih besar dan kompleks, integrasi dengan mekanisme *explainable AI*, serta evaluasi pada data *real-time* berbasis sensor IoT untuk validasi praktis di lapangan.

Ucapan Terima Kasih: Penulis mengucapkan terima kasih kepada dosen pembimbing dan seluruh pihak yang mendukung penelitian ini. Dataset yang digunakan bersumber dari Kaggle [12].

Konflik Kepentingan: Penulis menyatakan tidak ada konflik kepentingan.

Penggunaan Akal Imitasi (AI): Penulisan dibantu oleh AI menggunakan DeepSeek.

Referensi

1. Aslam, B.; Maqsoom, A.; Cheema, A.H.; Ullah, F.; Alharbi, A.; Imran, M. Water Quality Management Using Hybrid Machine Learning and Data Mining Algorithms: An Indexing Approach. *IEEE Access* **2022**, *10*, 119692–119705. <https://doi.org/10.1109/ACCESS.2022.3221430>.
2. Park, J.; Lee, W.H.; Kim, K.T.; Park, C.Y.; Lee, S.; Heo, T.Y. Interpretation of Ensemble Learning to Predict Water Quality Using Explainable Artificial Intelligence. *Science of The Total Environment* **2022**, *832*, 155070. <https://doi.org/10.1016/j.scitotenv.2022.155070>.
3. Ahmed, U.; Mumtaz, R.; Anwar, H.; Shah, A.A.; Irfan, R.; Garcia-Nieto, J. Efficient Water Quality Prediction Using Supervised Machine Learning. *Water* **2022**, *14*, 3235. <https://doi.org/10.3390/w14203235>.
4. Al Bataineh, A.; Vamsi, B.; Smith, S.A. A Hybrid Machine Learning Framework for Water Quality Index Prediction Using Feature-Based Neural Network Initialization. *IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing* **2026**, pp. 1–25. Early Access, <https://doi.org/10.1109/JSTARS.2026.3654017>.
5. Duan, T.; Anand, A.; Ding, D.; Thai, K.K.; Basu, S.; Ng, A.; Schuler, A. NGBoost: Natural Gradient Boosting for Probabilistic Prediction. In Proceedings of the Proceedings of the 37th International Conference on Machine Learning, 2020, Vol. 119, *Proceedings of Machine Learning Research*, pp. 2690–2700. arXiv:1910.03225.
6. Li, G.; Li, B.; Li, C.; Zeng, K.; Wang, S.; Chen, P. Battery State of Charge Probabilistic Estimation Using Natural Gradient Boosting. *IEEE Transactions on Industrial Electronics* **2024**, *71*, 10636–10646. <https://doi.org/10.1109/TIE.2023.3331136>.
7. Zhu, Y.; Hu, Y.; Liu, Q.; Liu, H.; Ma, C.; Yin, J. A Hybrid Approach for Predicting Corporate Financial Risk: Integrating SMOTE-ENN and NGBoost. *IEEE Access* **2023**, *11*, 111106–111125. <https://doi.org/10.1109/ACCESS.2023.3323198>.
8. Marzo, R.; Hein, E.; Al-Naser, M. Natural Gradient Boosting for Probabilistic Prediction of Somatic Mutations in Cancer. *BMC Bioinformatics* **2021**, *22*, 527. <https://doi.org/10.1186/s12859-021-04452-2>.
9. Uddin, M.G.; Nash, S.; Olbert, A.I. A Review of Water Quality Index Models and Their Use for Assessing Surface Water Quality. *Ecological Indicators* **2022**, *122*, 107218. <https://doi.org/10.1016/j.ecolind.2020.107218>.
10. Khoi, D.N.; Quan, N.T.; Linh, D.Q.; Nhi, P.T.T.; Thuy, N.T.D. Using Machine Learning Models for Predicting the Water Quality Index in the La Buong River, Vietnam. *Water* **2022**, *14*, 1552. <https://doi.org/10.3390/w14101552>.
11. Sakaa, B.; Elbeltagi, A.; Boudibi, S.; Chaffai, H.; Islam, A.R.M.T.; Kulimushi, L.C.; Choudhari, P. Water Quality Index Modeling Using Random Forest and Improved SMO Algorithm for Support Vector Machine in Saf-Saf River Basin. *Environmental Science and Pollution Research* **2022**, *29*, 48491–48508. <https://doi.org/10.1007/s11356-022-18644-x>.
12. Kadiwal, A. Water Quality. Kaggle, 2021. Dataset; diakses: 2024.
13. van Buuren, S.; Groothuis-Oudshoorn, K. mice: Multivariate Imputation by Chained Equations in R. *Journal of Statistical Software* **2011**, *45*, 1–67. <https://doi.org/10.18637/jss.v045.i03>.
14. Barrabes, M.; Perera, M.; Novelle Moriano, V.; Giro-i Nieto, X.; Mas Montserrat, D.; Ioannidis, A.G. Advances in Biomedical Missing Data Imputation: A Survey. *IEEE Access* **2025**, *13*, 16918–16932. <https://doi.org/10.1109/ACCESS.2024.3516506>.
15. Chawla, N.V.; Bowyer, K.W.; Hall, L.O.; Kegelmeyer, W.P. SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research* **2002**, *16*, 321–357. <https://doi.org/10.1613/jair.953>.
16. Batista, G.E.A.P.A.; Prati, R.C.; Monard, M.C. A Study of the Behavior of Several Methods for Balancing Machine Learning Training Data. *ACM SIGKDD Explorations Newsletter* **2004**, *6*, 20–29. <https://doi.org/10.1145/1007730.1007735>.
17. Amari, S. Natural Gradient Works Efficiently in Learning. *Neural Computation* **1998**, *10*, 251–276. <https://doi.org/10.1162/089976698300017746>.
18. Chen, T.; Guestrin, C. XGBoost: A Scalable Tree Boosting System. In Proceedings of the Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 2016, pp. 785–794. <https://doi.org/10.1145/2939672.2939785>.
19. Breiman, L. Random Forests. *Machine Learning* **2001**, *45*, 5–32. <https://doi.org/10.1023/A:1010933404324>.
20. Fawcett, T. An Introduction to ROC Analysis. *Pattern Recognition Letters* **2006**, *27*, 861–874. <https://doi.org/10.1016/j.patrec.2005.10.010>.
21. Guo, C.; Pleiss, G.; Sun, Y.; Weinberger, K.Q. On Calibration of Modern Neural Networks. In Proceedings of the Proceedings of the 34th International Conference on Machine Learning, 2017, Vol. 70, *Proceedings of Machine Learning Research*, pp. 1321–1330.
22. Dietterich, T.G. Approximate Statistical Tests for Comparing Supervised Classification Learning Algorithms. *Neural Computation* **1998**, *10*, 1895–1923. <https://doi.org/10.1162/089976698300017197>.

Catatan dari Penerbit: Ini adalah artikel penelitian mahasiswa.